




„ Bildverarbeitung“

Hochschule Niederrhein

Segmentierung

Roter Faden durch die Vorlesung

- Bildaufnahme
- Histogramme
- Grauwertmodifikation
- Glättungsfilter
- Kantenfilter
- Nichtlineare Filter
- **Segmentierung**
- Morphologische Operationen
- Fourier Transformation
- Anwendung der FFT
- Probeklausur




7 Segmentierung

Zerlegung eines Bildes in semantische Einheiten (d.h. in Strukturen, denen eine Bedeutung zugeordnet werden kann).

Segmente und nicht die Pixel sind die **Träger der Bedeutung** von Strukturen in einem Bild.

Datenreduktion: Grauwertbild → Binärbild



7 Segmentierung


Es gilt:

- Jedes Pixel gehört zu einer Region → Segmentierung ist vollständig
- Ein Pixel kann nicht zwei verschiedenen Regionen angehören → Segmente sind überdeckungsfrei
- Regionen sind maximal.
- Für jede Region gilt ein Homogenitätskriterium.
- Jedes Segment bildet ein zusammenhängendes Gebiet.

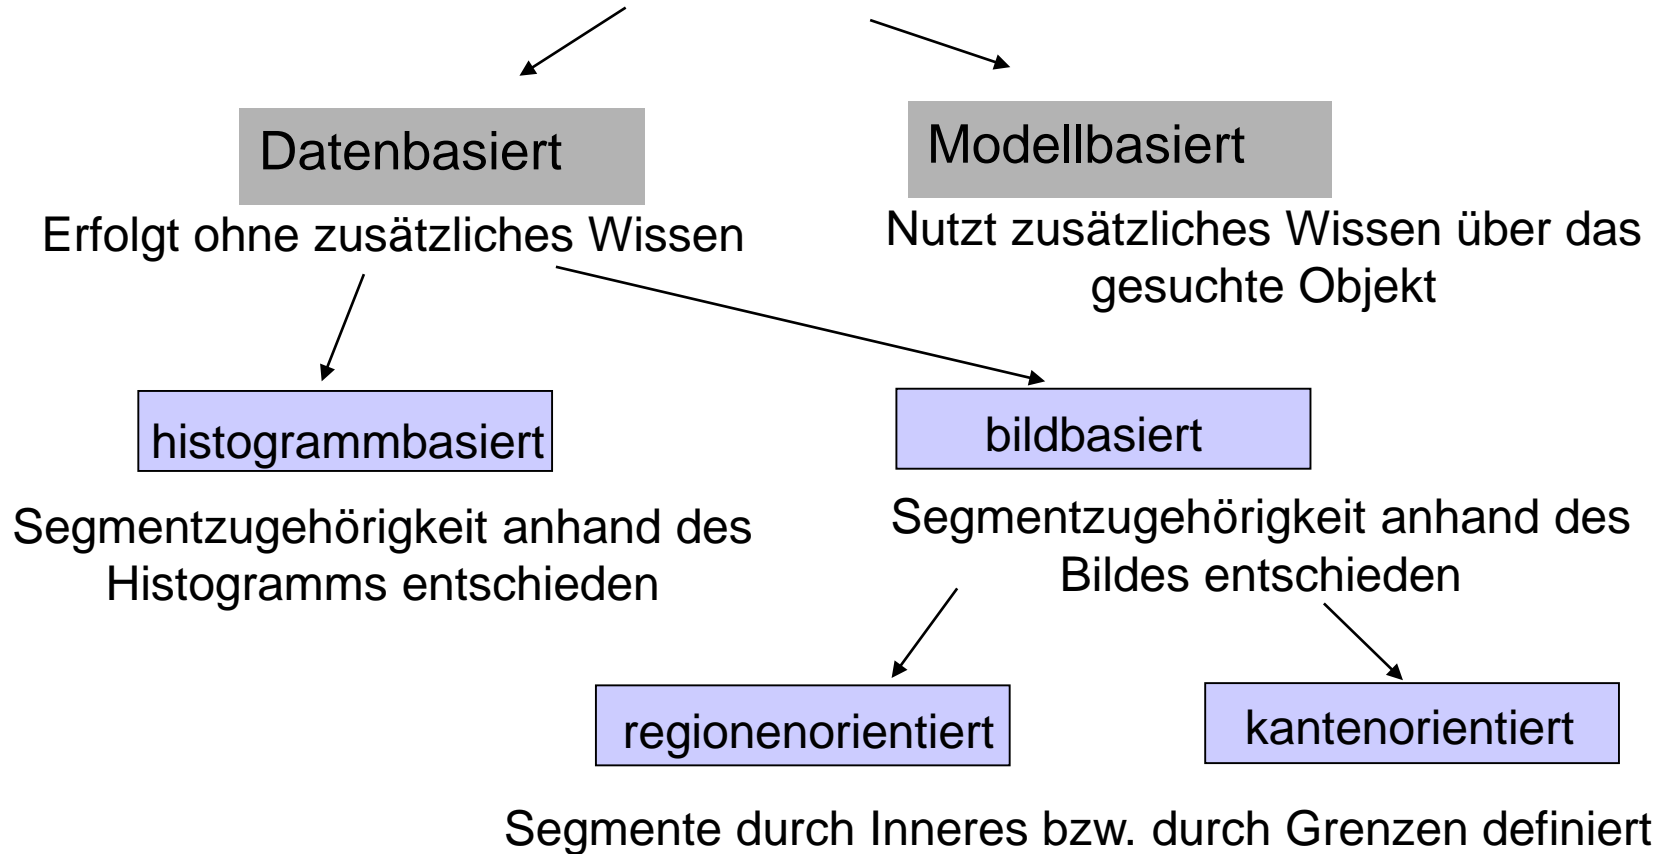
7 Segmentierung

Definitionen


- **Pfad:** Folge von benachbarten Pixeln, die eine Homogenitätsbedingung erfüllen. (Beachte: Unterschiedliche Pixel je nach Nachbarschaftsdefinition)
- **Zusammenhängendes Gebiet:** Menge aller Pixel zwischen denen Pfade existieren. (Beachte: Die Nachbarschaftsdefinitionen in Vorder- und Hintergrund müssen unterschiedlich sein.)



7 Segmentierung



7.1 Histogrammbasierte Segmentierung



Annahme: Bild besteht aus zwei Anteilen (Vordergrund-objekte und Hintergrund), die sich durch ihren Grauwert unterscheiden.

Aufgabe: Finde einen Schwellenwert (Threshold) zwischen den beiden Grauwerten.



Schwellen-
werte:

110

147



185

$$g(i,j) = \begin{cases} 1, & \text{falls } f(i,j) > thr \\ 0, & \text{sonst} \end{cases}$$

7.1 Histogrammbasierte Segmentierung

Voraussetzung: bimodales Histogramm

- Einfachste Vorgehensweise: Wahl des Minimums zwischen zwei Maxima als Schwellwert



7.1 Histogrammbasierte Segmentierung

Bimodalitätsprüfung

- Suche von 0 aus im Histogramm nach dem ersten lokalen Maximum \max_1 bei $g_{\max1}$
- Überprüfung, ob in bestimmtem Abstand von $g_{\max1}$ ein weiteres lokales Maximum existiert, das größer als \max_1 ist \rightarrow Aktualisiere \max_1 und $g_{\max1}$
- Suche von 255 aus im Histogramm nach einem lokalen Maximum \max_2 bei $g_{\max2}$
- Überprüfung, ob in bestimmtem Abstand von $g_{\max2}$ ein weiteres lokales Maximum existiert, das größer als \max_2 ist \rightarrow Aktualisiere \max_2 und $g_{\max2}$
- Untersuchung, ob zwischen $g_{\max1}$ und $g_{\max2}$ ein weiteres Maximum existiert \rightarrow kein bimodales Histogramm
- Suche nach dem Minimum \min und g_{\min} zwischen $g_{\max1}$ und $g_{\max2}$
- Wenn $\min/\max(g_{\max1}, g_{\max2}) < \text{Schwelle} \rightarrow$ bimodales Histogramm

7.1 Histogrammbasierte Segmentierung

Otsu Thresholding Verfahren

Wahl des Schwellwertes so, dass bestimmte Gütekriterien aus der Diskriminanzanalyse maximiert werden:

$$\lambda = \frac{\sigma_b^2}{\sigma_w^2}$$

$$\kappa = \frac{\sigma_T^2}{\sigma_w^2}$$

$$\eta = \frac{\sigma_b^2}{\sigma_T^2}$$

ω_i : Wahrscheinlichkeit der Klasse

σ_i^2 : Varianz der Klasse

$$\sigma_w^2 = \omega_1 \sigma_1^2 + \omega_2 \sigma_2^2$$

$$\sigma_b^2 = \omega_1 (\mu_1 - \mu_T)^2 + \omega_2 (\mu_2 - \mu_T)^2 = \omega_1 \omega_2 (\mu_2 - \mu_1)^2$$

$$\sigma_T^2 = \sum_{i=1}^L (i - \mu_T)^2 p_i$$

$$\sigma_w^2 + \sigma_b^2 = \sigma_T^2$$

Nur σ_w^2 und σ_b^2 hängen von der Schwelle ab.

Erstere beruht auf Statistik 2. Ordnung, letztere auf Statistik 1. Ordnung, deshalb gewählt

Otsu, N.: *A Threshold Selection Method from Grey-level Histograms*, IEEE Trans. on Systems, Man, and Cybernetics, vol. 9, no. 1(1979), pp. 377-393

7.1 Histogrammbasierte Segmentierung

Otsu Thresholding Verfahren

$$\eta(t) = \frac{\sigma_b^2(t)}{\sigma_T^2}$$

$$\sigma_b^2(t) = \frac{[\mu_T \omega(t) - \mu(t)]^2}{\omega(t)[1 - \omega(t)]}$$

$$\sigma_b^2(t^*) = \max_{1 \leq t \leq L} \sigma_b^2(t)$$

$$\omega(t) = \sum_{i=0}^t p_i$$



$$\mu(t) = \sum_{i=0}^t i \cdot p_i$$

Algorithmus

- Berechnung des Histogramms und des Bildmittelwerts μ_T
- Berechnung von initialer Wahrscheinlichkeit ω_0 und initialem Mittelwert μ_0
- Teste für alle möglichen Schwellwerte
 - Aktualisiere Wahrscheinlichkeit $\omega(t)$, Mittelwert $\mu(t)$ und Varianz $\sigma_b^2(t)$
- Wähle Schwellwert mit maximaler Varianz als optimalen Schwellwert

7.1 Histogrammbasierte Segmentierung



- **Problem:** Flächenanteil von Objekten kann so gering sein, dass er im Histogramm nicht sichtbar ist
- **Abhilfe:** Ausblenden der homogener Gebiete



7.1 Histogrammbasierte Segmentierung

Algorithmus:

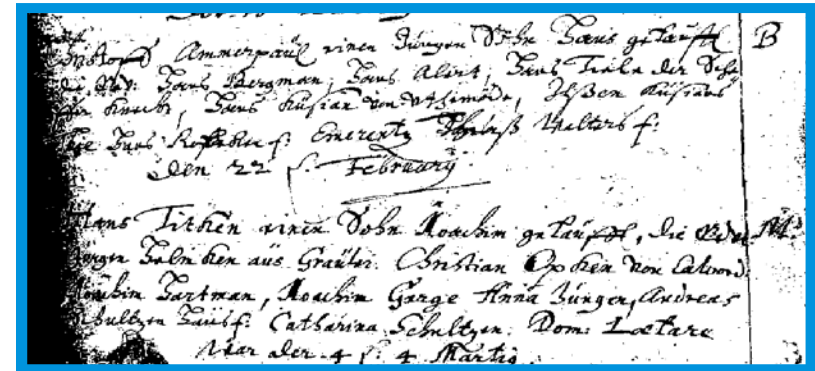
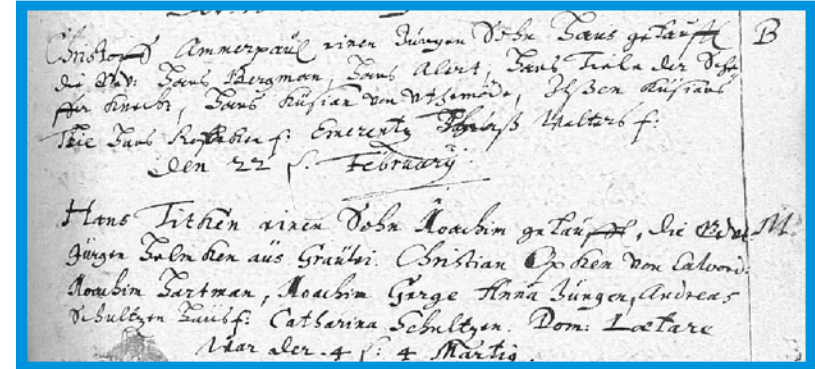
- Ermittlung des Betrags des Laplace-gefilterten Bildes
- Histogrammerstellung nur von den Bildpunkten, wo der Betragswert oberhalb einer Schwelle T ist



7.1 Histogrammbasierte Segmentierung

Problem:

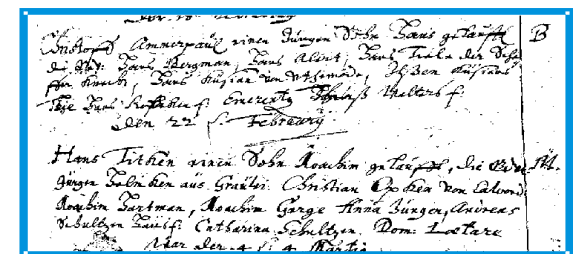

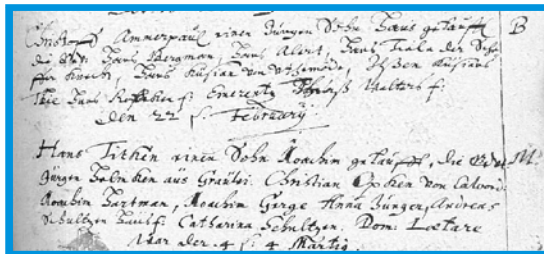
- Ungleichmäßige Ausleuchtung des Bildes → Shading
- Helligkeitsvariationen zerstören die bimodale Verteilung der Häufigkeiten.
- Schwellenwert ist nicht mehr für das gesamte Bild definierbar.



7.1 Histogrammbasierte Segmentierung

Abhilfe – 1. Variante

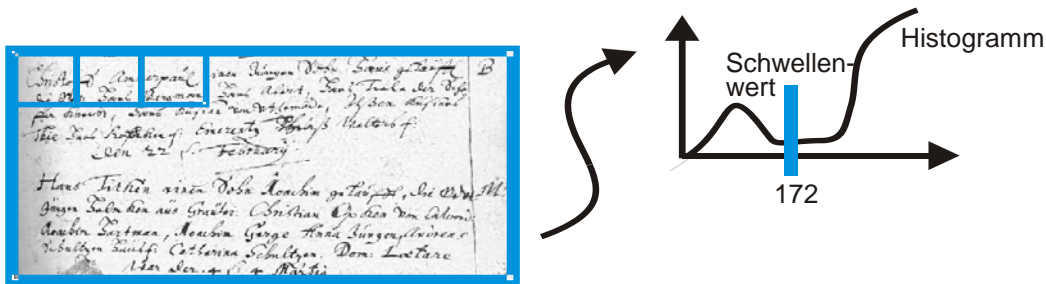
- Ermittlung eines Leerbildes durch
 - Aufnahme ohne Objekt (z.B. bei Mikroskopbildern)
 - Entfernen der Objekte aus dem Bild mit Hilfe von Filteroperationen
- Subtraktion des Originalbilds von Leerbild
- Anwenden einer festen Schwelle



7.1 Histogrammbasierte Segmentierung

Abhilfe – 2. Variante

- Ermittlung einer lokalen Schwelle aus Histogrammen in Teilregionen
 - Sicherstellung, dass Teilregion sowohl Vorder- als auch Hintergrund enthält
 - Größe der Teilregion muss klein genug sein, damit darin kein Shading auftritt
- Anwenden der lokalen Schwelle auf die Teilregion (besser Berechnung eines Schwellwertes für jeden Pixel über lineare Interpolation)



[1]

7.2 Bildbasierte Segmentierung

- **Regionenbasierte Segmentierung:** Suche nach Homogenität im Inneren des Objekts
- **Kantenbasierte Segmentierung:** Suche nach Inhomogenität am Rand des Objekts



7.2 Bildbasierte Segmentierung


Beispiel: Region Growing (Flood Filling) als regionenbasierte Segmentierung

Prinzip: Suche eines zusammenhängenden Gebiets, ausgehend von einem benutzerbestimmten Startpunkt (seed point)

Homogenitätsbedingungen: z.B. Grauwertbereich, Schwankung der Grauwerte

Homogenitätsbedingung:


$$g_{\text{Region}} = g_{\text{Seed}} \pm 20$$



7.2 Bildbasierte Segmentierung

Probleme beim Region Growing:

- „Auslaufen“ der Regionen (Homogenitätsbedingung zu weit gefasst)
- zu kleine Regionen (Homogenitätsbedingung zu eng gefasst)
- Rauschanfälligkeit
- Shading



7.2 Bildbasierte Segmentierung

Implementierung von Region Growing → Rekursive Version

```
RegionGrowing(B,x,y,label)
{
    if ((x,y) im Bild and B(x,y) erfüllt Homogenitäts-
    bedingung and B(x,y) != label)
    {
        B(x,y)=label
        RegionGrowing(B,x+1,y,label)
        RegionGrowing(B,x-1,y,label)
        RegionGrowing(B,x,y+1,label)
        RegionGrowing(B,x,y-1,label)
    }
}
```

7.2 Bildbasierte Segmentierung

Implementierung von Region Growing → Iterative Version

```
RegionGrowing(B,x,y,label)
{
    Anlegen einer leeren Liste Q
    Einfügen der Koordinaten des seed points in die Liste: In(Q,(x,y))
    while Q nicht leer do
    {
        Lesen der nächsten Koordinate vom Listenanfang (x,y)=Out(Q)
        if ((x,y) im Bild and B(x,y) erfüllt Homogenitätsbedingung
        and B(x,y) != label)
        {
            B(x,y)=label
            In(Q,(x+1,y))
            In(Q,(x-1,y))
            In(Q,(x,y+1))
            In(Q,(x,y-1))
        }
    }
}
```

Bildverarbeitung, Regina Pohle-Fröhlich, 7. Segmentierung


7.3 Region Labeling

Problem:

- nach Schwellwertentscheidung kein Zugriff auf einzelne Objekte im Bild, da alle gleich markiert sind
- Anzahl der Objekte und Größe sind unbekannt

Abhilfe:

- Nutzen von Region Growing zum Region Labeling
- Füllen jedes Segments mit eigenem Grauwert
- Histogramm des Bildes gibt Auskunft über Anzahl und Größe der Objekte



7.3 Region Labeling

Einfachster Algorithmus für das Region Labeling eines Binärbildes `bin`

```
RegionLabeling(bin)
{
    label=1
    for (y = 0 .. Zeilen-1)
        for (x = 0 .. Spalten-1)
            if (bin(x,y) gleich 255)
            {
                RegionGrowing(bin,x,y,label)
                label = label + 1;
            }
}
```

7.3 Region Labeling

Sequentielles Region Labeling

1. Schritt: Initiales Labeling

$$\mathcal{N}_4(u, v) = \begin{array}{|c|c|c|c|} \hline & & N_2 & \\ \hline N_1 & \times & & \\ \hline & & & \\ \hline \end{array} \quad \text{or} \quad \mathcal{N}_8(u, v) = \begin{array}{|c|c|c|c|} \hline & N_2 & N_3 & N_4 \\ \hline N_1 & \times & & \\ \hline & & & \\ \hline \end{array}$$

1. Fall: nur Hintergrund → Setze neues Label

0	0	0	0	0
0	0	1	1	0
1	1	1	1	0

0	0	0	0	0
0	0	2	1	0
1	1	1	1	0

2. Fall: nur ein Label → Setze Label

0	0	0	0	0
0	2	1	0	0
1	1	1	0	0

0	0	0	0	0
0	2	2	0	0
1	1	1	0	0

3. Fall: mehrere Label → Setze ein Label und registriere Kollision


0	0	0	0	0	0
0	0	0	0	2	2
5	5	5	1	1	1
0	0	0	1	0	1

0	0	0	0	0	0
0	0	0	2	2	2
5	5	5	2	1	1
0	0	0	1	0	1

[2]

7.3 Region Labeling

0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	2	2	0	0	3	3	0	4	0
0	5	5	5	2	2	2	0	0	3	0	0	4	0
0	0	0	0	2	0	2	0	0	0	0	0	4	0
0	6	6	2	2	2	2	2	2	2	2	2	2	0
0	0	0	0	2	2	2	2	2	2	2	2	2	0
0	7	7	0	0	0	2	0	2	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0



Knoten im ungerichteten Graphen korrespondieren mit den Labeln und Kanten mit den Kollisionen

2. Schritt: Auflösung der Kollisionen


Zuweisung der neuen Label anhand der aus dem Graphen abgeleiteten Zuweisungsvorschrift

0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	2	2	0	0	3	3	0	2	0
0	2	2	2	2	2	2	0	0	3	0	0	2	0
0	0	0	0	2	0	2	0	0	0	0	0	2	0
0	2	2	2	2	2	2	2	2	2	2	2	2	0
0	0	0	0	2	2	2	2	2	2	2	2	2	0
0	7	7	0	0	0	2	0	2	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0

[2]


7.4 Modellbasierte Segmentierung

Hough-Transformation: Suche nach Linien, Kreisen, Ellipsen



7.4 Modellbasierte Segmentierung


Hough-Transformation für Linien



Punkte auf einer Geraden: Erfüllen der Geradengleichung (gleiches k und d)
Ziel: Auffinden der Geraden mit den Parametern k und d , auf denen möglichst viele Punkte liegen.

7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien



Suche nach allen Geraden, die durch einen gegebenen Punkt $p_0 = (x_0, y_0)$ laufen


Beliebige Gerade L_j durch p_0 : $y_0 = k_j x_0 + d_j$

Menge aller Geraden durch p_0 ist ebenfalls eine Gerade: $d_j = -x_0 k_j + y_0$

Transformation aller Geraden durch alle Kantenpunkte vom Bildraum (x, y) in einen neuen Parameterraum (k, d)

7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien



[2]

Schnittpunkt von n Geraden im (k,d) -Parameterraum bedeutet, dass n Punkte auf der Geraden liegen


7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien

Akkumulator-Array: diskrete Realisierung des Parameterraums

Für jeden gefundenen Kantenpunkt p_0 werden die Zähler im Akkumulator-Array für alle möglichen Geraden durch diesen Punkt erhöht

Problem: senkrechte Geraden



[2]



7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien

Nutzung der Hesse'schen Normalform der Geradengleichung:

$$r = x \cdot \cos(\theta) + y \cdot \sin(\theta)$$



$$\text{mit } 0 \leq \theta < \pi \text{ und } -r_{\max} \leq r \leq r_{\max} \text{ mit } r_{\max} = \frac{1}{2} \sqrt{M^2 + N^2}$$




[2]

7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien



Im diskreten Bild:




7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien

```
1: HOUGHLINES( $I$ )
2:   Set up a two-dimensional array  $Acc[\theta, r]$  of counters, initialize to 0
3:   Let  $(u_c, v_c)$  be the center coordinates of the image  $I$ 
4:   for all image coordinates  $(u, v)$  do
5:     if  $I(u, v)$  is an edge point then
6:        $(x, y) \leftarrow (u - u_c, v - v_c)$  ▷ relative coordinate to center
7:       for  $\theta_i = 0 \dots \pi$  do
8:          $r_i = x \cos(\theta_i) + y \sin(\theta_i)$ 
9:         Increment  $Acc[\theta_i, r_i]$ 
10:   $MaxLines \leftarrow \text{FINDMAXLINES}(Acc, K)$ 
11:    ▷ return the list of parameter pairs  $(\theta_j, r_j)$  for  $K$  strongest lines
12:  return  $MaxLines$ .
```

7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien



[2]

Problem:


- Sinuskurven schneiden sich nicht genau an einem Punkt, sondern in einer Region
- Lokalisierung der Maxima ist schwierigster Teil der Hough-Transformation

7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien

Ansatz A:

- Schwellwertentscheidung: alle Akkumulatoreinträge unterhalb eines Schwellwertes werden verworfen, Ermittlung des Schwerpunkts der Regionen




[2]

7.3 Modellbasierte Segmentierung

Hough-Transformation für Linien

Ansatz B:

- Non-Maximum-Supression: alle Nicht-Maxima werden verworfen (Zellen, deren Einträge nicht größer als die aller Nachbarn sind), anschließend Schwellwertoperation





[2]

7.3 Modellbasierte Segmentierung

Template Matching:

Gegeben: Musters, dass die Form und die Orientierung, nicht aber die Position des gesuchten Segments enthält

Gesucht: Position des Musters im Bild



[2]

7.3 Modellbasierte Segmentierung


Messung der Ähnlichkeit (Abweichung) beim Template Matching:

Absolute Differenz:
$$d_A(r, s) = \sum_{(i, j) \in R} |I(r + i, s + j) - R(i, j)|$$

Maximale Differenz:
$$d_m(r, s) = \max_{(i, j) \in R} |I(r + i, s + j) - R(i, j)|$$

Summe der quadratischen Differenzen:
$$d_E(r, s) = \left[\sum_{(i, j) \in R} (I(r + i, s + j) - R(i, j))^2 \right]^{\frac{1}{2}}$$

7.3 Modellbasierte Segmentierung



Originalbild I



Referenzbild R


Probleme: robust gegenüber Rauschen, aber schlechte Resultate, wenn durchschnittliche Helligkeiten in Bild und Muster abweichen



Summe der Differenzbeträge



Maximaler Differenzbetrag



Summe der quadr. Abstände

[2]

7.3 Modellbasierte Segmentierung

Summe der quadratischen Differenzen

$$d_E^2(r, s) = \sum_{(i,j) \in R} (I(r+i, s+j) - R(i, j))^2 = \underbrace{\sum_{(i,j) \in R} I(r+i, s+j)^2}_{A(r,s)} + \underbrace{\sum_{(i,j) \in R} R(i, j)^2}_B - 2 \cdot \underbrace{\sum_{(i,j) \in R} I(r+i, s+j) \cdot R(i, j)}_{C(r,s)}$$

Minimum von d_E^2 entspricht dem Maximum von C = Korrelation


Besser normalisierte Korrelation

$$C_n(r, s) = \sum (I(r+i, s+j) - \bar{I}(r, s)) \cdot (R(i, j) - \bar{R})$$

oder Korrelationskoeffizient

$$C_L(r, s) = \frac{\sum (I(r+i, s+j) - \bar{I}(r, s)) \cdot (R(i, j) - \bar{R})}{\left(\sum (I(r+i, s+j) - \bar{I}(r, s))^2 \right)^{1/2} \cdot \left(\sum (R(i, j) - \bar{R})^2 \right)^{1/2}}$$

7.3 Modellbasierte Segmentierung



(a) Originalbild I



(b) Referenzbild R




(e) Summe der quadr. Abstände




(f) Globale Kreuzkorrelation




(c) Summe der Differenzbeträge



(d) Maximaler Differenzbetrag



(g) Normalisierte Kreuzkorrelation



(h) Korrelationskoeffizient

7.4 Kantenbasierte Segmentierung


Das Resultat des Gradientenoperators wird als Graph aufgefasst, auf dem **zwischen zwei Punkten ein optimaler Pfad** (entspricht **minimalen Kosten**) gesucht wird (Nutzung Dijkstra-Algorithmus)

Optimalitätskriterien:

- Maximierung der (durchschnittlichen) Gradientenlänge
- Minimierung der Pfadlänge
- Minimierung der Richtungsänderungen
- Minimierung der Grauwertänderungen



Vorteile:

- Globale Aspekte des Kantenzugs können eingebracht werden.
- Anfangs- und Endpunkt sind festgelegt.



7.4 Kantenbasierte Segmentierung

Einschränkung der Suche




- Kantenkandidaten durch Schwellenwert auf der Gradientenlänge generieren
- **Achtung:** Schwellenwert muss „großzügig“ sein, da sonst der Graph nicht verbunden ist.
- Zwischen zwei Knoten existiert eine Kante, wenn sie benachbart sind

7.4 Kantenbasierte Segmentierung

A*-Algorithmus


- Jedem Knoten werden neben Knotenkosten auch Pfadkosten zugewiesen.
- Wähle einen Startpunkt, dem seine Knotenkosten als Pfadkosten zugewiesen werden
- Alle anderen Knoten erhalten als Initialisierung maximale Pfadkosten
- Berechne für alle Nachbarknoten die Pfadkosten, sind diese geringer als die aktuell eingetragenen Pfadkosten, aktualisiere diese
- Übernimm diese in die Liste der aktuellen Knoten




7.4 Kantenbasierte Segmentierung

A*-Algorithmus

Entferne dasjenige Element aus der Liste der aktuellen Knoten mit den geringsten Pfadkosten und füge dessen nicht bereits besuchten Nachfolger in die Liste ein, falls die Pfadkosten geringer werden.




(a)




(b)

7.4 Kantenbasierte Segmentierung



7.4 Kantenbasierte Segmentierung




7.4 Kantenbasierte Segmentierung

A*-Algorithmus

Abbruch der Graphensuche: Falls Liste der aktuellen Knoten leer ist oder Endpunkt das erste Mal erreicht wurde

Ermittlung des günstigsten Pfads durch Back-Tracking:

Finden des Vorgängerknotens durch Vergleich der Pfadkosten mit den Pfadkosten der Vorgängerknoten und den Knotenkosten



7.4 Kantenbasierte Segmentierung

Korrekturmöglichkeiten

Problem: Kantenzug verläuft nicht entlang der gewünschten Richtung.

Lösungsmöglichkeiten:

- neue Stützpunkte setzen
- Gewichtungen für die Terme der Optimalitätsbedingung abändern

Terme der Optimalitätsbedingung:

- Abweichung der Gradientenlänge oder des Grauwerts von den erwarteten Werten (ggf. durch eine Lernphase erworben)
- Abweichung der Gradientenrichtung von der lokalen Kantenzugsrichtung
- Abweichung von der „Ideallinie“

7.4 Zusammenfassung

- Die Aufgabenstellung entscheidet über Auswahl des Segmentierungsverfahrens
- Schwellwertentscheidungen sind punktbasierte Verfahren und werten das Histogramm aus, welches deutlich ausgeprägte Maxima besitzen muss.
- Bei regionenbasierter Segmentierung wird zur Charakterisierung des Segments ein Homogenitätskriterium genutzt.
- Kantenbasierte Verfahren werten häufig den Gradienten zur Bestimmung der Objektgrenzen aus.
- Modellbasierende Verfahren nutzen objektcharakterisierendes Modellwissen zur Suche, dadurch sind sie nicht so flexibel einsetzbar.

Bildquellen

- [1] K. D. Tönnies: Grundlagen der Bildverarbeitung, Pearson Studium, 2005
- [2] W. Burger, M.J. Burge: Digitale Bildverarbeitung, Springer Verlag, 2005